

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ
РОССИЙСКОЙ ФЕДЕРАЦИИ

МГТУ им Н.Э.Баумана

Факультет ФН

Кафедра вычислительной математики и математической физики

Соколов Арсений Андреевич

Домашнее задание №1 по математической
статистике

3 курс, группа ФН11-53Б

Вариант 9

Преподаватель

_____ Т. В. Облакова

«___» _____ 2019 г.

Москва, 2019 г.

1 Подготовка данных

1.1 Поиск крайних элементов вариационного ряда

Импортируем данные, сохранённые в формате *.csv*, определяем максимальный, минимальный.

```
> df <- read.csv("db.csv", header = F) #data import
> max_el <- max(df)
> max_el
[1] 17.985
> min_el <- min(df)
> min_el
[1] 2.375
> range_el <- max_el - min_el
> range_el
[1] 15.61
```

1.2 Вариационный ряд

Выведем на печать упорядоченную выборку – вариационный ряд:

```
> sort(df$V1)
[1] 2.375 2.666 2.744 2.867 2.903 3.086 3.375
[8] 3.377 3.608 3.635 3.878 4.354 4.646 4.715
[15] 4.727 4.843 4.942 4.964 5.006 5.140 5.175
[22] 5.333 5.343 5.647 5.743 5.811 5.814 6.078
[29] 6.339 6.355 6.542 6.734 6.875 6.883 7.039
[36] 7.175 7.241 7.357 7.479 7.683 8.206 8.250
[43] 8.282 8.415 8.428 8.592 8.681 8.905 8.916
[50] 9.012 9.097 9.159 9.182 9.234 9.354 9.458
[57] 9.493 9.838 9.861 9.869 9.919 9.927 10.268
[64] 10.351 10.511 10.821 11.093 11.095 11.449 12.040
[71] 12.173 12.175 12.177 12.423 12.622 12.767 12.768
[78] 12.888 12.906 12.911 12.924 12.959 12.959 13.325
[85] 13.480 13.535 13.890 13.924 13.957 14.022 14.186
[92] 14.237 14.286 14.396 14.495 14.612 14.919 15.134
[99] 15.238 15.308 15.439 15.506 15.535 15.649 15.694
[106] 15.850 15.864 15.988 15.992 16.058 16.175 16.195
[113] 16.892 17.103 17.117 17.690 17.757 17.921 17.963
[120] 17.985
```

2 Построение гистограммы частот

2.1 Определение количества интервалов разбиения

Определим число "столбиков" гистограммы по правилу Стёрджеса:

$$n = 1 + \lceil \log_2 N \rceil,$$

где N – общее число наблюдений.

```
> num_bins = round(1 + log2(length(df$V1)))
> num_bins
[1] 8
```

2.2 Определение ширины интервала

Определим ширину интервала группировки по формуле:

$$\text{width} = \frac{\text{range}}{n},$$

где `range` – размах выборки.

```
> bin_width <- range_el / num_bins
> bin_width
[1] 1.95125
```

2.3 Построение графика

По полученным данным построим гистограмму частот:

```
> png(filename = "../img/hist_without_dens.png",
+       width = 1920, height = 1080,
+       pointsize = 24, res = 96 * 1.25)
> par(mar = c(3, 3, 2, 1), xaxs = "i", yaxs = "i")
> pl1 <- hist(df$V1,
+             breaks = seq(min_el, max_el, by = bin_width),
+             xlim = c(0, 20), ylim = c(0.00, 0.10),
+             axes = F, freq = F,
+             main = "Histogram of data")
> axis(1, seq(0, 20, 1))
> axis(2, seq(0.00, 0.10, 0.01), las = 1)
> grid(nx = 20, ny = 10, equilogs = F)
> dev.off()
```




Рис. 1: Гистограмма частот выборки.

2.4 Определение относительных частот

Для начала определим количество элементов в каждом интервале:

```
> pl1$counts
[1] 11 17 13 21 8 20 19 11
```

Посчитаем относительную частоту (эмпирическую вероятность) для каждого интервала:

```
> relative_freq <- pl1$counts / length(df$V1)
> relative_freq
[1] 0.09166667 0.14166667 0.10833333 0.17500000
[5] 0.06666667 0.16666667 0.15833333 0.09166667
```

2.5 Меры центральной тенденции

Определим выборочные среднее и медиану (мода в нашей выборке будет неинформативной):

```
> mean_el <- mean(df$V1)
> mean_el
[1] 10.2681
> median_el <- median(df$V1)
> median_el
[1] 9.894
```

2.6 Меры изменчивости

Определим размах(определялся ранее), дисперсию и стандартное отклонение:

```
> range_el
[1] 15.61
> var_el <- var(df$V1)
> var_el
[1] 19.61091
> sd_el <- sd(df$V1)
> sd_el
[1] 4.42842
```

3 Определение возможного закона распределения

3.1 Предварительный анализ

Анализ возможного закона распределения начнём с построения Cullen and Frey skewness-kurtosis графика, предварительно забустрэпив 10^4 ресэмплов:

```
> png(filename = "../img/cullen_and_frey_graph.png",
+       width = 1920, height = 1080,
+       pointsize = 24, res = 96 * 1.25)
> descdist(df$V1, method = "sample", boot = 1e4)
summary statistics
```

```
min: 2.375    max: 17.985
median: 9.894
mean: 10.2681
sample sd: 4.40993
sample skewness: -0.02444883
sample kurtosis: 1.822814
> dev.off()
```

Где $kurtosis = \frac{\mu_4}{\sigma^4} - 3$ – это коэффициент эксцесса, а $skewness = \frac{\mu_3}{\sigma^3}$ – коэффициент асимметрии.




Рис. 2: Cullen and Frey skewness-kurtosis plot.

Из Рис. 2 мы видим, что наша выборка близка больше всего к uniform – равномерному распределению и beta – бета-распределению. Так же рассмотрим нормальное распределение для сравнения моделей.

Для анализа нашего датасета на принадлежность к бета-распределению, зарескейлим данные к интервалу $[0; 1]$:

```
> library(scales)
> res <- rescale(df$V1)
> res
[1] 0.77642537 0.19013453 0.77008328 0.67347854
[5] 0.00000000 0.43939782 0.22011531 0.15067265
[9] 0.15810378 0.06418962 0.40397181 0.62767457
[13] 0.14990391 1.00000000 0.39827034 0.50563741
[17] 0.99590006 0.23721973 0.31172325 0.14548366
[21] 0.48379244 0.88532992 0.16854580 0.98539398
[25] 0.30749520 0.87232543 0.37354260 0.43606662
[29] 0.43062140 0.16585522 0.22030750 0.84304933
[33] 0.86412556 0.61915439 0.07898783 0.28878924
[37] 0.38776425 0.73766816 0.75989750 0.20960922
[41] 0.86322870 0.25496477 0.04554773 0.48327995
[45] 0.08071749 0.66579116 0.03151826 0.01864190
[49] 0.55848815 0.47809097 0.31915439 0.37841127
[53] 0.58129404 0.74196028 0.28827675 0.94439462
```

```
[57] 0.99859065 0.02363869 0.62793081 0.47956438
[61] 0.06406150 0.73984625 0.54106342 0.03382447
[65] 0.55861627 0.67495195 0.09628443 0.51095452
[69] 0.37636131 0.75663037 0.84119154 0.21575913
[73] 0.67463165 0.42517617 0.66572710 0.87206919
[77] 0.45598975 0.85323511 0.18949391 0.92998078
[81] 0.17713004 0.44708520 0.34003844 0.88404869
[85] 0.38693145 0.45374760 0.87655349 0.67802691
[89] 0.62780269 0.76303652 0.81736067 0.64368994
[93] 0.27924407 0.83689942 0.74612428 0.82850737
[97] 0.41902627 0.98110186 0.67802691 0.80358744
[101] 0.32696989 0.48007687 0.67578475 0.52120436
[105] 0.65643818 0.78392056 0.94349776 0.29878283
[109] 0.71140295 0.26694427 0.12677771 0.25393978
[113] 0.71492633 0.17937220 0.43459321 0.16444587
[117] 0.70147341 0.85035234 0.41832159 0.82402306
```

Составим наши модели, отталкиваясь от метода моментов:

```
> fit.norm <- fitdist(df$V1, "norm", method = "mme")
> fit.uniform <- fitdist(df$V1, "unif", method = "mme")
> fit.beta <- fitdist(res, "beta", method = "mme")
```

Рассмотрим критерии Колмогорова-Смирнова и Крамера-Мизеса:

```
> stat_normal <- gofstat(fit.norm,
+                         fitnames = c("normal"))
> stat_unif <- gofstat(fit.uniform,
+                      fitnames = c("uniform"))
> stat_beta <- gofstat(fit.beta,
+                      fitnames = c("beta"))
>
> stat_table <- cbind(rbind(stat_normal$ks, stat_normal$cvm),
+                     rbind(stat_unif$ks, stat_unif$cvm),
+                     rbind(stat_beta$ks, stat_beta$cvm))
> rownames(stat_table) <- c("Kolmogorov-Smirnov statistic",
+                           "Cramer-von Mises statistic")
> stat_table
```

	normal	uniform	beta
Kolmogorov-Smirnov statistic	0.08952502	0.04535694	0.04307507
Cramer-von Mises statistic	0.22184007	0.03095026	0.02950918

Отчётливо видно преобладание равномерного и бета-распределений с небольшим преимуществом у бета-распределения.

Построим несколько графиков:

```

> png(filename = "../img/fit_norm.png",
+      width = 1920, height = 1080,
+      pointsize = 24, res = 96 * 1)
> plot(fit.norm)
> dev.off()
> png(filename = "../img/fit_unif.png",
+      width = 1920, height = 1080,
+      pointsize = 24, res = 96 * 1)
> plot(fit.uniform)
> dev.off()
> png(filename = "../img/fit_beta.png",
+      width = 1920, height = 1080,
+      pointsize = 24, res = 96 * 1)
> plot(fit.beta)
> dev.off()

```

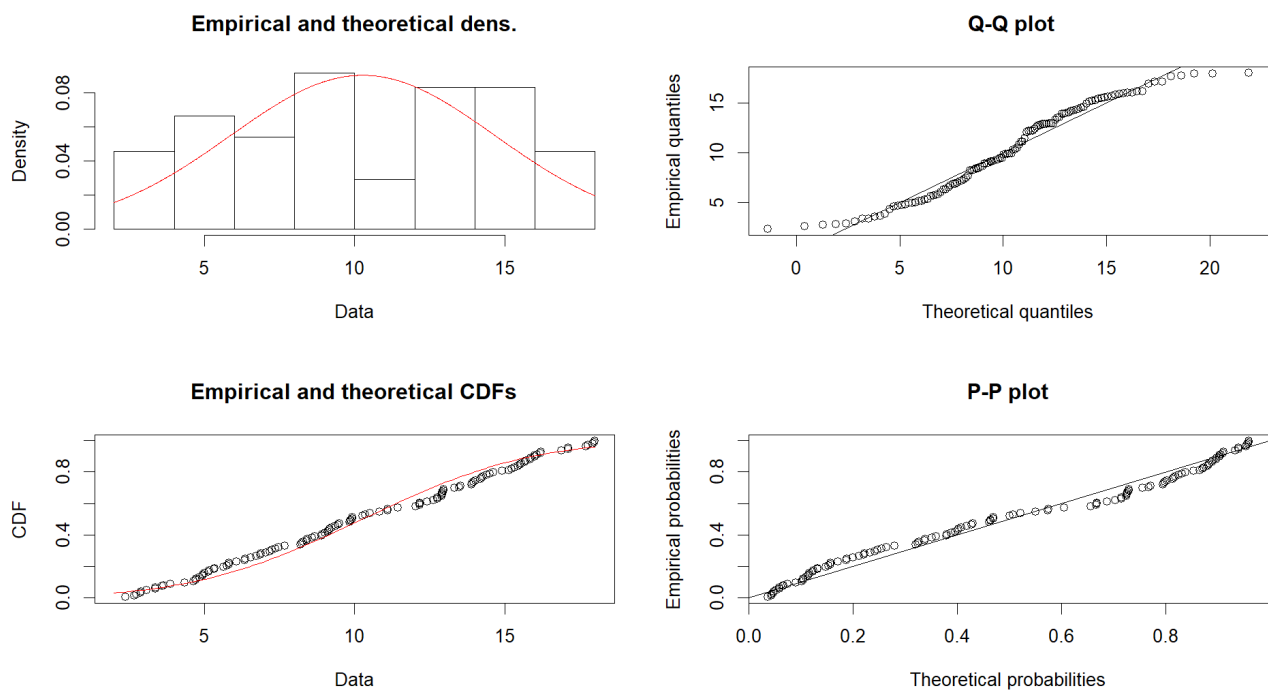


Рис. 3: Нормальное распределение.

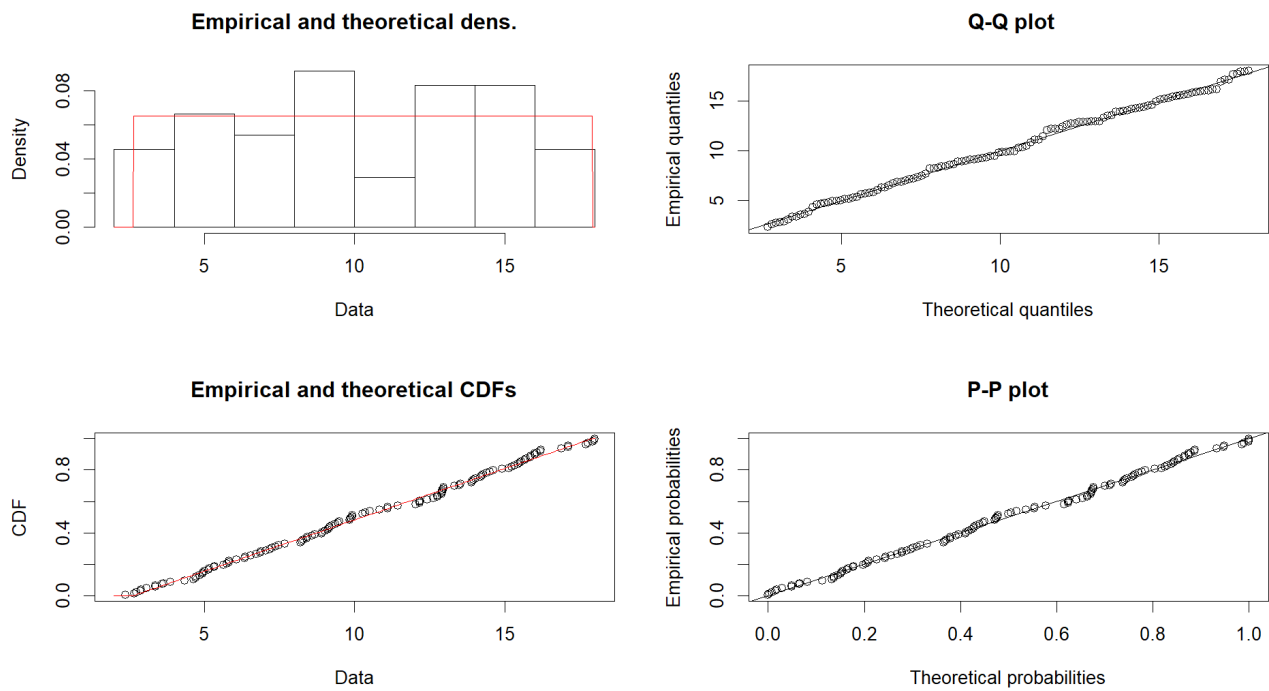


Рис. 4: Равномерное распределение.

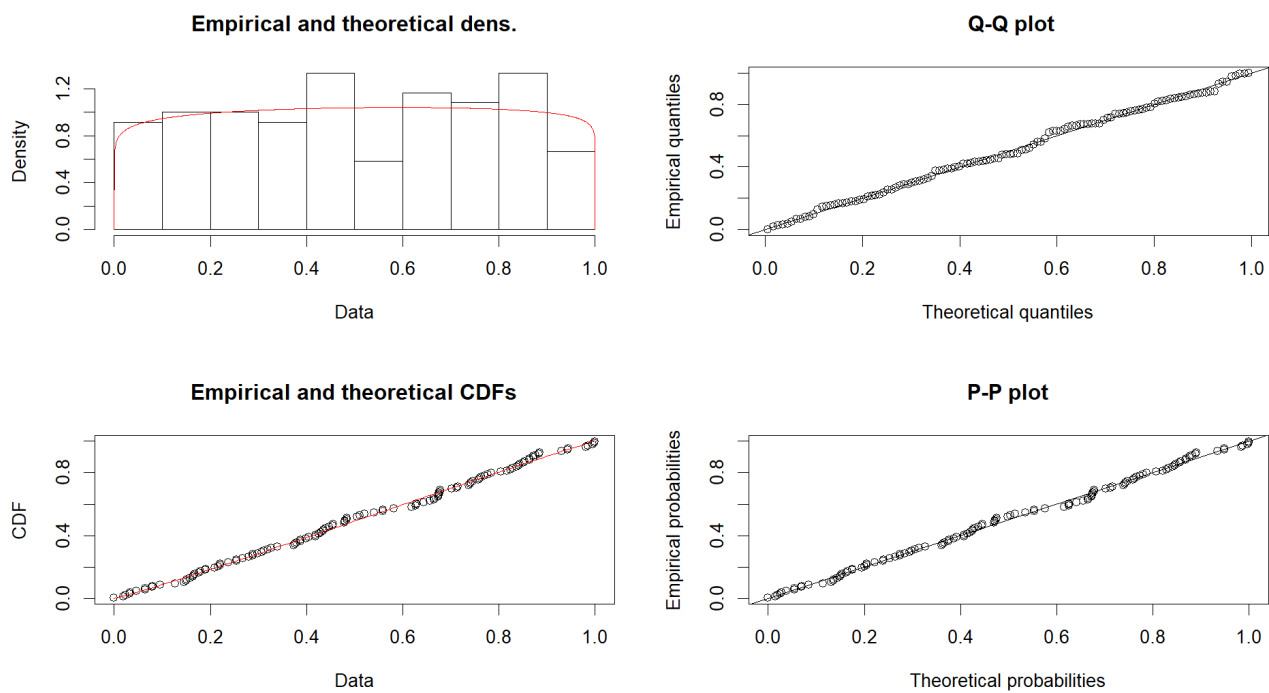


Рис. 5: Бета-распределение.

Для простоты дальнейшего анализа рассмотрим равномерное распределение.

3.2 Оценка параметров распределения методом моментов

Для оценки параметров методом моментов приравняем выборочные моменты распределения (среднее значение и несмещенную дисперсию) к теоретическим:

$$\hat{\mu}_1 = \frac{1}{N} \sum_{k=1}^N x_k = \mathbb{E}[X]$$

$$\hat{\mu}_2 = \frac{1}{N-1} \sum_{k=1}^N (x_k - \bar{x})^2 = D[X]$$

Рассмотрим равномерное распределение. Его плотность:

$$f_X(x) = \begin{cases} \lambda e^{-\lambda x}, & x \geq 0 \\ 0, & x < 0 \end{cases}$$

И соответствующие моменты:

$$\mathbb{E}[X] = \frac{a+b}{2}$$

$$D[X] = \frac{(b-a)^2}{12}$$

Тогда составим систему:

$$\begin{cases} \mathbb{E}[X] = \frac{a+b}{2} = 10.2681 \\ D[X] = \frac{(b-a)^2}{12} = 19.6109 \end{cases}$$

Мы видим, что полученная система состоит из двух симметрических многочленов, поэтому будет иметь место два симметричных решения, из которых следует выбрать то решение, где $b > a$:

$$\begin{cases} a = 2.597 \\ b = 17.938 \end{cases}$$

Тогда исходная случайная величина имеет непрерывное равномерное распределение на отрезке $[a; b] = [2.597; 17.938]$ и ее плотность $f_X(x)$ имеет вид:

$$f_X(x) = \begin{cases} \frac{1}{15.341}, & x \in [2.597; 17.938] \\ 0, & x \notin [2.597; 17.938]. \end{cases}$$

3.3 Построение совмещённого графика гистограммы и плотности предполагаемого закона

По полученным ранее данным, построим совмещённые графики плотности равномерного закона и нашей гистограммы:

```
png(filename = "../img/hist_with_unif_dens.png",
width = 1920, height = 1080,
pointsize = 24, res = 96 * 1.25)
par(mar = c(3, 3, 2, 1), xaxs = "i", yaxs = "i")
pl1 <- hist(df$V1,
breaks = seq(min_el, max_el, by = bin_width),
xlim = c(0, 20), ylim = c(0.00, 0.10), axes = F, freq = F,
main = "Histogram of data")
axis(1, seq(0, 20, 1))
axis(2, seq(0.00, 0.10, 0.01), las = 1)
grid(nx = 20, ny = 10, equilogs = F)
curve(dunif(x, 2.5978, 17.9383), 2.5978, 17.9383,
xlim = c(0, 20), add = T, col = "red", lwd = 3)
legend("topright", c("uniform density"),
lty=c(1),
fill=c("red"))
dev.off()
```




Рис. 6: Совмещённый график гистограммы и плотности равномерного закона.

4 Эмпирическая функция распределения

Эмпирическая CDF (Cumulative Distribution Function) является непараметрической оценкой неизвестной генеральной функции распределения случайной величины. При ее построении выборку X предварительно сортируют по возрастанию наблюдаемых величин, каждому исходному элементу присваивают значения вероятности $1/n$, и далее на каждом шаге с использованием интерполяции вычисляют сумму этих вероятностей:

```
> n <- length(df$V1)
> x <- sort(df$V1)
> vals <- unique(x)
> rval <- approxfun(vals,
+                   cumsum(tabulate(match(x, vals)))/n,
+                   method = "constant", yleft = 0, yright = 1, f = 0,
+                   ties = "ordered")
```

Эмпирическая CDF определяется как

$$\hat{F}_n(x) = \hat{P}_{n(X \leq x)} = n^{-1} \sum_{i=1}^n I(x_i \leq x),$$

где I – индикаторная функция, принимающая два возможных значения:

$$I(x_i \leq x) = \begin{cases} 1, & \text{если } x_i \leq x \\ 0, & \text{если } x_i > x \end{cases}$$

Согласно теореме Гливенко-Кантели, $\hat{F}_n(x)$ является состоятельной оценкой $F_n(x)$ и равномерно сходится к ней при $n \rightarrow \infty$.

На практике построение эмпирической CDF может оказаться полезным по следующим причинам:

- если совокупный размер исходных выборок достаточно велик, то CDF является аппроксимацией "истинной" функции распределения, что может быть полезным для проверки статистических гипотез;
- график эмпирической CDF можно визуально сравнить с аналогичными кривыми для часто используемых теоретических распределений и проверить, не распределена ли случайная величина по известному закону;
- CDF может графически отобразить насколько "быстро" (с оценкой коэффициента угла наклона отрезков прямых на графике) вероятности увеличиваются от 0 до 1;

Построим совмещённые графики эмпирической и теоретической функций распределения:

```

> png(filename = "../img/emp_and_theor_CDF.png",
+       width = 1920, height = 1080,
+       pointsize = 24, res = 96 * 1.25)
> plot(ecdf(x),
+       main = "Empirical and theoritical distribution functions",
+       lwd = 3, col = "lightgreen")
> lines (x, (1:n)/n, type = 's',
+        col="blue", lwd = 2)
> curve(punif(x, 2.5978, 17.9383), 2.5978, 17.9383,
+        xlim = c(0,20), add = T,
+        col = "red", lwd = 3)
> legend("bottomright",
+        c("emperical CDF", "theoritical CDF"),
+        lty = 1, col = c("blue", "red"))
> dev.off()

```




Рис. 7: Совмещённый график эмпирической и теоретической функций распределения.

Из Рис. 7 мы видим, что наши данные хорошо аппроксимируются полученной ранее предполагаемой функцией распределения.

5 Выводы

Основываясь на полученных в пунктах 1–4 данных, целесообразно заключить, что исходные данные подчиняются равномерному распределению с параметрами $a = 2.597$, $b = 17.938$ и соответствующей плотностью распределения:

$$f_X(x) = \begin{cases} \frac{1}{15.341}, & x \in [2.597; 17.938] \\ 0, & x \notin [2.597; 17.938]. \end{cases}$$

В итоге проделанной работы на предоставленных в таблице исходных данных, были:

- определены крайние члены вариационного ряда,
- определено оптимальное количество интервалов, на которые разбивается наблюдаемый диапазон изменения случайной величины при построении гистограммы плотности её распределения, по правилу Стёрджеса,
- определена ширина соответствующих интервалов разбиения для гистограммы,
- построена гистограмма частот нашей выборки,
- определены относительные частоты для каждого разбиения,
- определены меры центральной тенденции и меры изменчивости,
- произведён предварительный анализ наших данных с целью выбора оптимальной модели распределения с помощью построения графика Cullen and Frey skewness-kurtosis, а так же с помощью анализа критериев Колмогорова-Смирнова и Крамера-Мизеса,
- выбрана наиболее оптимальная модель, основываясь на предварительном анализе данных – модель, соответствующая равномерному распределению,
- оценены параметры соответствующего распределения методом моментов,
- построены совмещённые графики гистограммы и плотности предполагаемого закона,
- определена эмпирическая функция распределения,
- построены совмещённые графики эмпирической и предполагаемых функций распределения,
- сделан окончательный вывод о распределении исходных данных.